

浙江大学实验报告

姓名：_____ 专业： 信息工程 _____ 学号： _____
课程名称： 人工智能 _____ 任课老师： _____
实验名称： 基于 CCT 的 Fashion MNIST 图像分类 _____

1 实验目的和要求

1.1. 实验目的

- 深入理解 Vision Transformer (ViT) 的机制，以及 Compact Convolutional Transformer (CCT) 引入卷积特征提取以解决小数据集泛化瓶颈的底层原理；
- 熟练掌握 PyTorch 深度学习框架，通过代码补全掌握模型特征提取与序列池化 (Sequence Pooling) 的构建逻辑；
- 运用控制变量法，系统性评估学习率、批大小、优化器类型及学习率调节策略等超参数对模型收敛速度与泛化能力的影响；
- 掌握深度学习训练过程中过拟合 (Overfitting)、梯度爆炸 (Gradient Explosion) 与局部震荡发散等异常现象的判定标准及成因分析；

1.2. 实验要求

- 在给定的代码框架基础上，完善 CCT 架构，补全 Convolutional Tokenizer 与 Sequence Pooling 模块。
- 完善 test_process() 测试流程，实现对测试集总体准确率和各类别准确率的统计与输出。
- 严格遵循模块化实验设计，开展多组控制变量实验，通过 TensorBoard 记录并对比训练/验证集曲线，撰写具备理论支撑的实验分析报告。

2 实验原理

本次实验旨在利用 Transformer 架构完成图像分类任务。相较于传统卷积神经网络 (CNN)，Transformer 具备更强的全局建模能力，但面临对数据量要求过高的局限性。

2.1. Vision Transformer (ViT) 的局限性

ViT 的核心机制是将图像等分为固定大小的图块 (Patch)，并通过线性映射展平为一维 Token 序列。该方法缺乏 CNN 固有的“平移不变性”和“局部感受野”等归纳偏置，导致其在小规模数据集（如 28x28 分辨率的 Fashion MNIST）上特征提取效率低，极易出现过拟合。

2.2. Compact Convolutional Transformer (CCT) 的架构优化

为提升 Transformer 在小规模数据集上的 Train-from-scratch 能力, CCT 进行了以下优化:

- (1) 卷积分词器 (Convolutional Tokenizer): 使用轻量级 CNN 模块替代 ViT 的线性映射。CNN 的滑动窗口操作有效保留了图像的局部连续性与底层纹理信息, 为模型注入了先验的空间归纳偏置;
- (2) 序列池化 (Sequence Pooling): 摒弃静态的 [CLS] Token, 采用基于注意力的加权池化策略。通过线性层评估序列中各 Token 的重要性分数, 并经 Softmax 归一化后对全局序列进行加权求和, 提升了序列信息的聚合效率;

2.3. 优化算法与超参数调优

2.3.1. 优化算法原理

1. 随机梯度下降 (SGD)

核心优化算法。利用损失函数的一阶偏导数 (梯度) 来更新网络权重。结合动量 (Momentum) 机制后, 可利用历史梯度信息加速收敛并越过浅层局部极小值。

- (1) 优点: 具备优秀的全局收敛能力, 在长期训练后通常能获得更高的泛化性能上限; 更新轨迹相对稳健;
- (2) 缺点: 初期收敛速度较慢; 对初始学习率高度敏感, 且对所有网络参数均采用相同的全局学习率;

2. 自适应矩估计 (Adam)

高阶优化算法。综合了梯度的一阶矩 (均值) 和二阶矩 (未中心化的方差), 为每个参数计算自适应的独立更新步长。

- (1) 优点: 初期收敛极快; 能为不同参数自动调整学习步长, 对稀疏梯度表现良好;
- (2) 缺点: 在高度非凸的复杂网络 (如 Transformer) 中, 后期极易因自适应步长缩放过大而在极小值附近产生剧烈震荡; 泛化性能上限通常略低于精心调参的 SGD;

2.3.2. 超参数控制机制

1. 初始学习率 (Learning Rate, LR): 决定参数更新步长的全局绝对缩放因子; 设定过大易导致越过极小值甚至引发梯度爆炸; 设定过小则会导致陷入局部极优或收敛迟缓 (欠拟合);
2. 批大小 (Batch Size): 决定单次计算梯度的样本数量; Batch Size 控制着真实梯度的估计方差: 值较小时随机噪声大, 有助于跳出局部极小值但易引起震荡; 值较大时梯度方向更稳定, 但单轮 Epoch 内更新次数减少;
3. 学习率调节器 (Scheduler): 动态超参数控制策略; 在训练中后期通过特定函数动态衰减学习率, 有效抑制模型在最优解附近的震荡, 辅助模型逼近全局最优;

3 实验内容

本实验采用控制变量法，划分为四个核心探究模块：

1. 模块一：探究学习率 (Learning Rate) 的影响

控制变量：criterion = cross_entropy, optimizer = sgd, epochs = 20, batch_size = 128

实验组别：

1.1	--lr 1e-3 (偏小)
1.2	--lr 1e-2 (基准)
1.3	--lr 1e-1 (偏大)

2. 模块二：探究批大小 (Batch Size) 的影响

控制变量：criterion = cross_entropy, optimizer = sgd, lr = 1e-2, epochs = 20

实验组别：

2.1	--batch_size 32 (较小)
2.2[1.2]	--batch_size 128 (基准)
2.3	--batch_size 512 (较大)

3. 模块三：探究优化器与学习率调节器的组合策略

控制变量：criterion = cross_entropy, epochs = 20, batch_size = 128

实验组别：

3.1[1.2]	纯 SGD (lr 1e-2)
3.2	纯 Adam (lr 1e-3)
3.3	SGD + Scheduler
3.4	Adam + Scheduler

4. 模块四：长周期训练与过拟合测试

将模块三中四种优化策略组合的训练轮数均延长至 epochs = 50，观测并分析模型拟合状态的演变及过拟合临界点。


控制变量：criterion = cross_entropy, epochs = 50, batch_size = 128

4.1[1.2]	纯 SGD (lr 1e-2)
4.2	纯 Adam (lr 1e-3)
4.3	SGD + Scheduler
4.4	Adam + Scheduler

4 实验结果和分析


4.1. 学习率尺度对模型收敛性的影响

本模块通过对比三种量级的初始学习率（LR），探究步长对梯度下降过程的实质影响。



实验分析：

- (1) 偏小学习率 ($1e-3$, 橙线)：曲线整体呈下降趋势，但斜率较小。由于更新步长受限，在 20 轮训练结束时模型仍处于欠拟合状态，未能触及泛化性能上限。
- (2) 适中学习率 ($1e-2$, 蓝线)：模型表现出正常的收敛特征，val/loss 稳步下降并趋于平缓，验证集准确率最终突破 90%，属于当前配置下的最优解。




LR = 1e-3

LR = 1e-2


- (3) 偏大学习率 ($1e-1$, 红线)：终端输出 NaN or Inf found in input tensor 异常。由于学习率过大导致更新步幅跨度远超损失函数的合理曲率，引发了梯度爆炸现象。参数数值溢出变为 NaN 后，Softmax 输出失效，底层 argmax 函数默认返回首个索引，导致模型在测试时强行将所有样本判定为第一类 (T-shirt/top, 见下图)。此现象印证了超参数

越界对神经网络权重的破坏性。



4.2. 批大小 (Batch Size) 对梯度估计方差的影响

本模块测试不同批大小对训练轨迹稳定性和收敛效率的作用。




实验分析：

- (1) 较小批大小 (bs=32, 青线)： 由于单次计算使用的样本数量较少，梯度估计方差较大。这种随机噪声在初期加速了 Loss 下降，但在中后期导致了 val/loss 的高频震荡，阻碍了模型在极小值谷底的精细收敛。
- (2) 基准批大小 (bs=128, 深蓝线)： 在兼顾梯度估计精度的同时，保证了充足的迭代次

数，在限定轮数内实现了最高效的性能提升，是本实验条件下的局部最优平衡点。

- (3) 较大批大小（bs=512，粉线）：梯度方向具有极高的准确性，因此曲线形态最为平滑。但因单轮 Epoch 内参数更新的总次数减少了四倍，导致整体训练进度大幅落后，在 20 轮结束时仍处于未完全收敛状态。




bs=32

bs=128

bs=512

4.3. 优化器特性与学习率衰减策略的分析

本模块采用 2x2 消融实验设计，对比 Adam 与 SGD 的差异，及引入 Scheduler 对训练后期的平抑作用。




实验分析：

- (1) 纯 Adam 的局部发散现象（青绿线）：Adam 优化器在前 3 轮展现出极快的收敛效率，但随后验证集 Loss 出现剧烈的锯齿状反弹，准确率显著下降。这表明在 Transformer 这类对超参数高度敏感的架构中，自适应动量在缺乏外部约束时，极易在


局部最优解附近产生严重的过度冲调，根据下面的准确率图可以发现，准确率相对其他几个模型有较大的下滑。

- (2) Scheduler 对 Adam 的修正作用（橙线 vs 青绿线）：引入学习率动态衰减后，橙色曲线的剧烈震荡被完全抑制，val/loss 持续平稳下探。说明 Scheduler 通过后期动态压缩步长，有效限制了 Adam 的过量动能，提升了收敛的稳定性。
- (3) SGD 机制的稳定性考察（深蓝线 vs 灰线）：纯 SGD（深蓝线）因不具备自适应加速机制，更新步态相对稳健，未出现大幅发散。加入 Scheduler 的 SGD（灰线）与其在前 15 轮高度重合，但在末期表现出更平滑的损失波动，反映出固定学习率下的微小震荡得到了进一步平抑。



SGD

Adam




SGD + Scheduler

Adam + Scheduler

4.4. 长周期探究与过拟合 (Overfitting) 的边界判定


本模块将训练周期统一延长至 50 轮，重点观察泛化能力的衰退与 Scheduler 的长期干预效果。




实验分析：

- 典型过拟合现象判定（纯 SGD，深蓝线）：观测曲线可知，约在 Epoch 20 时，train/loss 持续逼近于 0 且 train/accuracy 接近 100%。然而，同时期的 val/loss 触极小值后开始呈现 U 型反转并持续上升，val/accuracy 陷入停滞。此数据分离现象是判定过拟合的标准依据，表明模型在此节点后开始过度拟合训练集的专有噪声，导致泛化性能受损。20 轮即为该配置下的最佳早停节点。
- 纯 Adam 的严重发散现象（红线）：观察红色曲线可知，在脱离 Scheduler 约束的长周期训练中，纯 Adam 展现出了极端的局部发散。其在验证集上的 Loss 出现高频且剧烈的锯齿状震荡，甚至向上突破了初始损失水平，对应的验证集准确率也发生大幅退化。这进一步印证了 Transformer 架构对 Adam 参数自适应步幅的高度敏感性，证明了在长周期中独立使用 Adam 具有极高的发散风险。
- Scheduler 干预的异质性表现：
 - Adam 组合（粉线）：配合 Scheduler 后，Adam 在长周期内完美维持了最优泛化能力，val/loss 未出现反弹。说明学习率衰减有效地“冻结”了 Adam 的自适应动量，规避了特征过拟合。
 - SGD 组合（浅蓝线）：值得注意的是，加入 Scheduler 的 SGD（浅蓝线）与纯 SGD 的过拟合轨迹高度重合。归因分析认为：SGD 的收敛轨迹具有强惯性，当 Scheduler 基于设定的 Milestone 开始大幅衰减时，模型已实质性进入过拟合空间。单纯的步长缩减


只能减缓其在该空间内的游走速度，无法逆转其发散的轨迹。




SGD



Adam




SGD + Scheduler



Adam + Scheduler

4.5. 对识别率柱形图的解释



柱形图可见，训练好的模型识别正确率的方差也较大。主要是以下原因（以 SGD，epoch = 50 组为例）：

(1) 类间形态高度相似

模型在“上装”类别上极易容易发生混淆。比如 Shirt(衬衫 78.1%)、T-shirt/top(T 恤 84.3%)、Pullover(套头衫 86.8%) 和 Coat(外套 90.3%)。它们在轮廓上都有躯干和袖子，几何形态的重叠度极高。模型很难在有限的感受野内提取出具有决定性差异的特征。

(2) 独有特征的显著性差异

与上装的“大混战”不同，Trouser(裤子 98.3%)、Bag(包 97.6%) 以及三类鞋子 Sandal(凉鞋 98.0%)、Sneaker(运动鞋 97.2%)、Ankle boot(短靴 96.5%) 的外轮廓极其独特。裤子的双腿结构、鞋子的底部特征，使得它们几乎不可能与其他类别混淆，因此模型能够极其轻松地将它们的准确率刷到 96% 以上。

(3) 数据集的分辨率与通道限制（细粒度信息丢失）

Fashion MNIST 是 28×28 的灰度图。在这个极低的分辨率下，很多用于区分衬衫和 T 恤的“细粒度特征”（如领子的形状、纽扣的存在、布料的纹理、甚至拉链）在降维成像素点时已经完全丢失或模糊化了。模型只能依靠宏观轮廓去猜，导致相近类别的方差极大。

5 实验结论

通过对 CCT 架构在 Fashion MNIST 数据集上的系统性实验评估，得出以下结论：

- 1.架构效能：CCT 利用卷积层提取底层特征，成功赋予了网络空间归纳偏置，显著缓解了标准 ViT 在小数据集上的数据不足问题。
- 2.超参数敏感度控制：Transformer 架构对学习率量级高度敏感。粗放的超参数设定极易诱发梯度爆炸或陷入局部震荡发散。
- 3.训练策略耦合必要性：独立使用具有自适应机制的 Adam 优化器存在极大的震荡风险。必须严格搭配学习率动态衰减策略(Scheduler)，通过约束后期步长，方能兼顾前期的极速收敛与后期的精准微调。
- 4.生命周期科学管理：延长训练周期并非提升性能的绝对途径。通过动态监控验证集损失曲线，精确捕捉特征拟合与噪声过拟合的临界点（如本实验中 SGD 对应的 Epoch 20），并实施停止干预，是保障深度学习模型工程实用性的核心环节。